Predictor de Ingresos: Evaluación y Análisis Ético de un Modelo de Regresión Logística

Santiago Nieto Rodríguez

Facultad de Ingeniería, Universidad de La Salle

Teoría de la Computación II: Actividad 6, Mini-proyecto

Rodrigo Aranda Fernández

6 de noviembre de 2026

Predictor de Ingresos: Evaluación y Análisis Ético de un Modelo de Regresión Logística

En este mini-proyecto construí un modelo sencillo de *machine learning*, medí qué tan bien funciona y analicé sus riesgos éticos. El modelo responde una pregunta concreta: a partir de datos como la edad, la educación, la ocupación y las horas de trabajo, ¿la persona gana más de 50.000 dólares al año? Para responderla usé una regresión logística entrenada con el conjunto de datos *Adult*, que proviene del censo de Estados Unidos de 1994 (Becker & Kohavi, 1996).

Todo el trabajo se puede revisar y volver a ejecutar desde el repositorio del proyecto, en la rama **develop**, que es la que se debe calificar: https://github.com/santnier92/proyectoFinal_predictorIngresos/tree/develop (Nieto Rodríguez, 2026). Allí están el código, el modelo entrenado, las pruebas automáticas, los diagramas de arquitectura, las decisiones técnicas (ADR) y este informe.

El documento sigue el orden de la actividad. Primero explico por qué elegí el modelo y cómo son los datos. Luego presento las métricas y la matriz de confusión. Después analizo los sesgos, la equidad, la privacidad y el impacto social del modelo. Al final cierro con las conclusiones y algunas recomendaciones para mejorarlo. La Tabla 1 resume los resultados principales.

Tabla 1

Resumen de indicadores clave del modelo (conjunto de prueba)

Indicador clave (conjunto de prueba)	Valor
Accuracy / baseline	0.8562 / 0.7606
F1-score clase >50K	0.6736
ROC-AUC	0.9095
Criterios de aceptación cumplidos	5 de 5
Brecha de recall (TPR) hombres vs mujeres	0.170

Nota. El baseline es un modelo de referencia que siempre predice la clase mayoritaria (≤50K).

Selección del Modelo

Elegí la **regresión logística**. Este modelo calcula la probabilidad de que una persona gane más de 50K combinando sus variables en una fórmula lineal que luego pasa por la función sigmoide: $P(y=1|x) = 1 / (1 + e^{-(\beta_0 + \beta \cdot x)})$. Lo elegí por cuatro razones:

- **Encaja con el problema.** La respuesta es sí o no (clasificación binaria) y los datos vienen en una tabla.
- **Se puede explicar.** Cada variable tiene un coeficiente que dice si sube o baja la probabilidad de ganar más de 50K, y cuánto. Esto es clave para el análisis ético, porque permite ver qué está mirando el modelo para decidir.
- **Da probabilidades, no solo etiquetas.** Así se puede mover el punto de corte según qué error resulte más costoso.
- **Rinde igual que un árbol de decisión.** El árbol obtuvo un F1 de 0.6822 y la regresión logística 0.6736. La diferencia (0.009) es menor que la variación normal entre particiones de la validación cruzada (0.012), así que en la práctica empatan.

Descarté KNN porque, después de convertir las categorías en columnas, quedan 84 variables. Con tantas dimensiones las distancias entre puntos pierden sentido, cada predicción es lenta y el modelo no ofrece una explicación general. El hiperparámetro de la regresión logística se eligió con validación cruzada de cinco particiones y el mejor valor fue **C = 1.0** (Pedregosa et al., 2011).

Descripción del Conjunto de Datos

El conjunto *Adult* tiene **48.842 registros y 15 columnas** y se publica con licencia CC BY 4.0 (Becker & Kohavi, 1996). Solo el **23.9 %** de las personas gana más de 50K, así que las clases están desbalanceadas. También encontré 52 registros duplicados y datos faltantes, marcados con «?», en las columnas workclass (2.799), occupation (2.809) y native_country (857). La Tabla 2 describe cada variable.

Tabla 2

Variables del conjunto de datos Adult y su uso en el modelo

Variable	Tipo	Descripción	Uso en el modelo
age	Numérica	Edad en años	Feature
workclass	Categórica	Tipo de empleador	Feature
fnlwgt	Numérica	Peso muestral del censo	Descartada (no describe a la persona)
education	Categórica	Nivel educativo en texto	Descartada (redundante)
education_num	Numérica	Nivel educativo 1–16	Feature
marital_status	Categórica	Estado civil	Feature (proxy de sexo)
occupation	Categórica	Ocupación	Feature
relationship	Categórica	Rol en el hogar	Feature (proxy de sexo)
race	Categórica	Raza	Feature sensible / auditada
sex	Categórica	Sexo	Feature sensible / auditada
capital_gain / capital_loss	Numéricas	Ganancias y pérdidas de capital	Features
hours_per_week	Numérica	Horas trabajadas por semana	Feature
native_country	Categórica	País de origen	Feature sensible / auditada
income	Binaria	>50K (1) o <=50K (0)	Variable objetivo

Nota. Una variable *proxy* no es sensible por sí misma, pero está muy relacionada con una que sí lo es.

La Tabla 3 muestra cinco registros reales del archivo, para dar una idea de cómo se ven los datos.

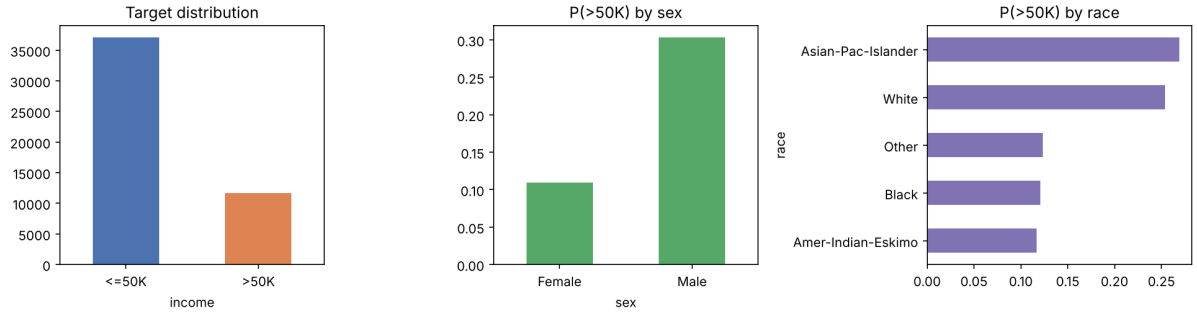
Tabla 3

Muestra de registros del conjunto de datos

age	workclass	education_num	occupation	sex	race	hours	income
39	State-gov	13	Adm-clerical	Male	White	40	<=50K
50	Self-emp-not-inc	13	Exec-managerial	Male	White	13	<=50K
38	Private	9	Handlers-cleaners	Male	White	40	<=50K
31	Private	14	Prof-specialty	Female	White	50	>50K
42	Private	13	Exec-managerial	Male	White	40	>50K

Figura 1

Distribución de la variable objetivo y proporción de personas con ingresos mayores a 50K por sexo y raza



Nota. Elaboración propia con los datos originales de Becker y Kohavi (1996).

Objetivo del modelo. Aprender la relación entre las 12 variables de entrada y la variable *income*, para estimar la probabilidad de que una persona nueva gane más de 50K al año.

Metodología

Seguí las siete etapas del flujo de trabajo de *machine learning* vistas en clase. Cada etapa tiene su propio módulo en el repositorio y queda registrada en un cuaderno de Jupyter ya ejecutado. La Tabla 4 resume qué hice en cada una.

Tabla 4

Etapas del flujo de trabajo de machine learning aplicadas en el proyecto

Etapa	Qué se hizo
1. Definir la tarea	Clasificación binaria >50K vs <=50K; métrica principal: F1 de la clase positiva.
2. Recolectar datos	Carga del CSV de UCI con verificación SHA-256 y perfil del dataset.
3. Representar la entrada	Deduplicación antes de partir los datos (48.790 filas); partición estratificada 80/20 (train 39.032 / test 9.758); imputación (mediana / 'Unknown'), escalado estándar y one-hot (84 variables) dentro de un Pipeline.
4. Elegir el modelo	Baseline (clase mayoritaria), Regresión Logística, Árbol de Decisión y Regresión Logística sin atributos sensibles.
5. Entrenar	GridSearchCV con 5 folds estratificados, optimizando F1, solo sobre train.
6. Evaluar	Métricas en test, matriz de confusión, curva ROC, análisis de umbral, coeficientes, auditoría de equidad y criterios de aceptación.
7. Usar con datos nuevos	CLI src.predict: recibe un CSV y devuelve la probabilidad y la clase.

Un cuidado importante fue evitar la fuga de información. El conjunto de prueba se separó desde el principio y no se usó para entrenar ni para elegir hiperparámetros. Además, todas las transformaciones de los datos se ajustan solo con los datos de entrenamiento.

Métricas de Evaluación

Todas las métricas se calcularon con el **conjunto de prueba**, que tiene 9.758 registros que el modelo nunca vio. La Tabla 5 compara los cuatro modelos.

Tabla 5

Desempeño de los modelos en el conjunto de prueba

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Baseline (clase mayoritaria)	0.7606	0.0000	0.0000	0.0000	0.5000
Regresión Logística	0.8562	0.7376	0.6199	0.6736	0.9095
Árbol de Decisión	0.8660	0.7888	0.6010	0.6822	0.9113
Reg. Logística sin atributos sensibles	0.8554	0.7385	0.6130	0.6699	0.9090

Nota. La regresión logística es el modelo seleccionado. Valores con umbral de decisión de 0.5.

En palabras sencillas, cada métrica responde una pregunta distinta. La Tabla 6 explica qué significa cada valor de la regresión logística en este problema.

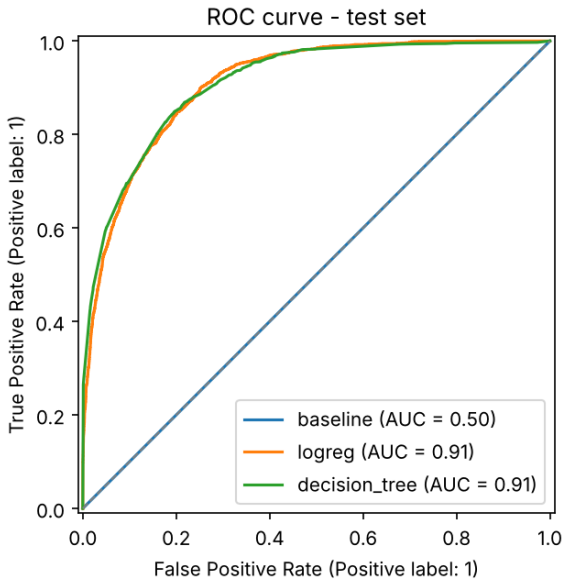
Tabla 6

Interpretación de las métricas de la regresión logística

Métrica	Valor	Qué significa en este problema
Accuracy	0.8562	Acierta con el 85.6 % de las personas. Pero ojo: un modelo que siempre dice «≤50K» ya acierta el 76.1 % sin aprender nada. La mejora real es de +9.6 puntos. Cuando las clases están desbalanceadas, la accuracy sola engaña.
Precision	0.7376	De cada 100 personas que el modelo marca como >50K, unas 74 sí lo son. Indica qué tanto confiar en un «sí» del modelo.
Recall	0.6199	Encuentra al 62.0 % de quienes de verdad ganan >50K; se le escapa el 38.0 %. Indica cuántos casos positivos logra detectar.
F1-score	0.6736	Equilibra precision y recall en un solo número. Es la métrica principal porque castiga los dos tipos de error. El baseline saca 0.
ROC-AUC	0.9095	Si se toma al azar una persona con >50K y otra con ≤50K, el modelo le da más probabilidad a la primera en el 91.0 % de los casos. No depende del punto de corte.
CV F1 (5 folds)	0.6565 ± 0.0118	El resultado casi no cambia entre particiones distintas del entrenamiento, así que no es cuestión de suerte.

Figura 2

Curvas ROC de los modelos en el conjunto de prueba

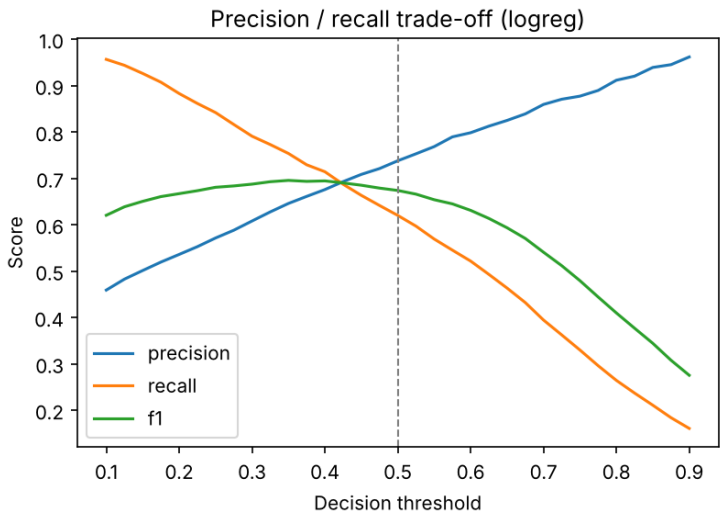


Nota. El baseline coincide con la diagonal (AUC = 0.5), que equivale a adivinar al azar.

Punto de corte. Por defecto el modelo dice «>50K» cuando la probabilidad supera 0.5. Con ese valor es prudente: acierta mucho cuando dice que sí, pero deja pasar varios casos. Si el corte baja a **0.35**, el F1 sube a **0.695**, porque el modelo detecta más casos a cambio de equivocarse un poco más. Elegir el corte no es solo una decisión técnica: depende de qué error resulta más grave en el uso real (Figura 3).

Figura 3

Precision, recall y F1 según el punto de corte de la regresión logística

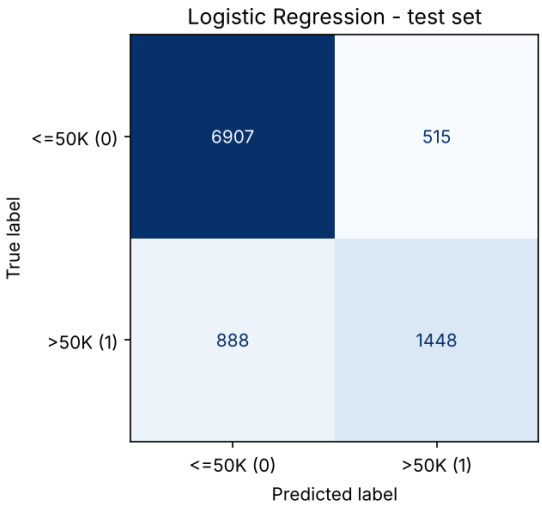


Matriz de Confusión

La matriz de confusión cruza lo que el modelo predijo con lo que realmente pasó. Así se ven los aciertos y los dos tipos de error por separado (Figura 4 y Tabla 7).

Figura 4

Matriz de confusión de la regresión logística



Nota. Conjunto de prueba con umbral de decisión de 0.5. Clase 1 = ingresos mayores a 50K.

Tabla 7

Significado de cada celda de la matriz de confusión

Celda	Valor	Significado en este problema
Verdaderos positivos (VP)	1.448	Personas que ganan >50K y el modelo las reconoció bien.
Falsos positivos (FP)	515	Personas que ganan ≤50K, pero el modelo dijo >50K. En un uso real, por ejemplo un crédito, se le podría aprobar a alguien que no puede pagarlo. Es el error de *sobreestimar*.
Verdaderos negativos (VN)	6.907	Personas que ganan ≤50K y el modelo acertó. Es la celda más grande porque es la clase más común.
Falsos negativos (FN)	888	Personas que ganan >50K, pero el modelo dijo ≤50K. Se les *subestima* y podrían perder oportunidades. Explican el recall de 0.62 y, como se ve más adelante, afectan más a mujeres y a personas negras.

El modelo comete más falsos negativos (888) que falsos positivos (515). Es decir, es **conservador**: le cuesta decir que alguien gana más de 50K. Es lo esperable con clases desbalanceadas y un corte de 0.5. En comparación, el baseline tiene 0 verdaderos positivos y 2.336 falsos negativos: no encuentra a nadie de la clase positiva.

Análisis Ético

Un modelo puede tener buenas métricas y aun así ser injusto. Por eso revisé de dónde vienen los sesgos, a quién afectan los errores y qué condiciones harían falta para usar el modelo de forma responsable (Barocas et al., 2023).

Sesgos del Conjunto de Datos

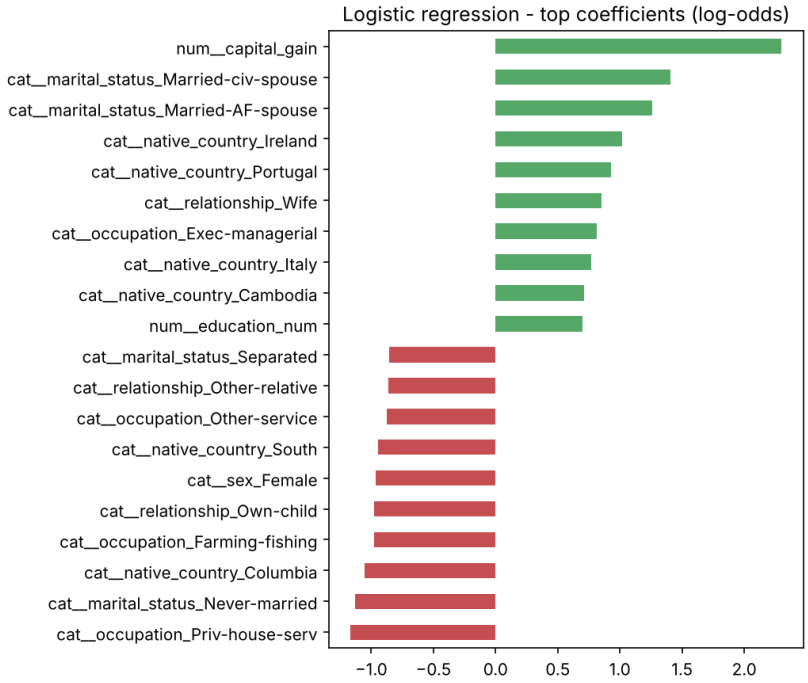
- **Sesgo histórico.** El censo de 1994 refleja las desigualdades de esa época. El 30.4 % de los hombres gana más de 50K, frente al 10.9 % de las mujeres. Las personas blancas y asiáticas superan en más del doble a las personas negras e indígenas. El modelo aprende esas brechas como si fueran algo normal.
- **Sesgo de representación.** El 85.5 % de los registros son de personas blancas y el 66.8 % de hombres. Grupos como Amer-Indian-Eskimo (cerca de 470 registros) u Other (cerca de 400) tienen tan pocos datos que sus métricas no son confiables.
- **Sesgo de medición.** Las categorías de raza y sexo son cerradas, y el límite de 50K está en dólares de 1994, sin ajustar por costo de vida ni por región.
- **Sesgo temporal y geográfico.** Los datos no representan la economía de hoy ni la de Colombia. Usar el modelo fuera de ese contexto sería extrapolar sin fundamento.

Sesgos del Modelo

Los coeficientes muestran que el modelo usa el sexo de forma directa. La variable **sex_Female** tiene un coeficiente de **-0.967**: si todo lo demás es igual, ser mujer baja la probabilidad estimada de ganar más de 50K. También pesan mucho el estado civil **Married-civ-spouse** (+1.41) y la relación **Own-child** (-0.98), que funcionan como variables *proxy* del sexo y de la etapa de vida. Además, algunos países con muy pocos registros, como Columbia (-1.05), reciben coeficientes extremos. Esto muestra que el modelo es inestable con esos grupos y que puede discriminar por origen (Figura 5).

Figura 5

Los 20 coeficientes de mayor magnitud de la regresión logística



Nota. Los valores están en log-odds. En verde los que aumentan la probabilidad de ganar más de 50K y en rojo los que la disminuyen.

Equidad: Métricas por Grupo

Para medir la equidad usé dos criterios. La **paridad demográfica** pregunta si el modelo dice «>50K» con la misma frecuencia en cada grupo. La **igualdad de oportunidad** pregunta si el modelo encuentra por igual a quienes sí ganan más de 50K en cada grupo, es decir, si el recall es parecido (Hardt et al., 2016). La Tabla 8 muestra los resultados.

Tabla 8

Métricas de la regresión logística por sexo y raza

Grupo	n (test)	Tasa real >50K	Tasa predicha >50K	TPR (recall)	FPR	Accuracy
Male	6432	0.304	0.269	0.648	0.104	0.821
Female	3326	0.115	0.070	0.478	0.017	0.925
White	8353	0.255	0.216	0.628	0.074	0.850
Black	916	0.123	0.079	0.460	0.025	0.912
Asian-Pac-Islander	311	0.228	0.244	0.676	0.117	0.836

Nota. Solo se incluyen grupos con al menos 100 registros en el conjunto de prueba. TPR = tasa de verdaderos positivos; FPR = tasa de falsos positivos.

- **Sexo.** El modelo encuentra al 64.8 % de los hombres que ganan más de 50K, pero solo al 47.8 % de las mujeres en la misma situación (diferencia de 0.170). Una mujer que sí gana bien tiene más probabilidad de ser subestimada.
- **Raza.** El recall de las personas negras (46.0 %) es mucho menor que el de las personas blancas (62.8 %). La diferencia máxima entre grupos es de 0.216.
- **Impacto dispar.** La razón entre las tasas de selección de mujeres y hombres es 0.26, muy por debajo de la regla de los cuatro quintos (0.80), que se usa como referencia en contextos laborales de Estados Unidos.
- **La accuracy puede engañar.** La accuracy es *mayor* en mujeres (92.5 %) que en hombres, porque la mayoría de ellas está en la clase ≤50K. Por eso no basta con mirar la accuracy por grupo; hay que revisar el recall.
- **Quitar las variables sensibles no basta.** Sin sex, race y native_country, la paridad por sexo apenas pasa de 0.199 a 0.192 y la igualdad de oportunidad de 0.170 a 0.146. Las variables relationship (Husband/Wife) y marital_status siguen revelando el sexo.

Privacidad y Uso Responsable de los Datos

- El conjunto de datos es público, no tiene nombres ni identificadores y su licencia (CC BY 4.0) permite usarlo citando la fuente, como se hace en este informe.
- Aun así, contiene **datos sensibles**: raza, sexo, origen y estado civil. En Colombia, la Ley 1581 de 2012 exige autorización previa, una finalidad clara y protección reforzada para este tipo de datos (Congreso de la República de Colombia, 2012). Un sistema real no podría usarlos sin cumplir esos requisitos.
- Existe riesgo de **reidentificación**: al combinar edad, ocupación, país y horas de trabajo se podría identificar a una persona dentro de un grupo pequeño. Por eso el modelo no se publica como servicio ni se cruza con otras fuentes.
- Se aplicó el principio de **minimización**: se descartó fnlwgt y se recomienda no recolectar datos que el caso de uso no necesite.

Impacto Social

Si un modelo así se usara para aprobar créditos, cupos, empleos o subsidios, sus falsos negativos caerían sobre todo en mujeres y personas negras. Se les negarían oportunidades a personas que sí cumplen el criterio, y eso reforzaría la misma desigualdad que originó los datos, en un círculo vicioso. En el otro sentido, los falsos positivos podrían llevar a otras personas a endeudarse más de lo que pueden pagar. Que el algoritmo sea neutral en lo matemático no hace que su impacto sea neutral.

Justicia y Transparencia en la Toma de Decisiones

- **Transparencia.** Con la regresión logística se puede explicar cada predicción, porque se ve cuánto aporta cada variable. Además, el repositorio publica los datos, el código, las métricas por grupo y las decisiones técnicas, para que cualquiera pueda auditarlos.
- **Justicia.** No hay una sola definición de equidad. Cuando las tasas reales de los grupos son distintas (30 % frente a 11 %), no se puede cumplir a la vez la paridad demográfica y la igualdad de oportunidad. Elegir cuál priorizar es una decisión ética que deben

tomar las personas afectadas y los responsables del sistema, no solo el equipo técnico.

- **Supervisión humana.** El modelo debería apoyar la decisión, no tomarla solo. Las personas afectadas deberían poder conocer la razón de la decisión y apelarla.
- **Rendición de cuentas.** Se recomienda acompañar el modelo con una *model card* que diga para qué sirve, cuáles son sus límites y cómo rinde en cada grupo (Mitchell et al., 2019).

Conclusiones Técnicas

- **Técnicamente, el modelo funciona bien.** Obtuvo un F1 de 0.6736, un ROC-AUC de 0.9095 y una accuracy de 0.8562. Supera con claridad al baseline (F1 de 0 y AUC de 0.5) y cumple los **cinco criterios de aceptación** definidos.
- **No hay sobreajuste.** El F1 en entrenamiento (0.6588) y en prueba (0.6736) es casi el mismo, y varía poco entre particiones (± 0.0118).
- **Los resultados son confiables.** Ningún registro está a la vez en entrenamiento y prueba. Además, el modelo rinde mejor con perfiles que nunca vio (0.691) que con perfiles repetidos (0.602), así que su resultado no depende de haber memorizado casos.
- **Su punto débil es el recall** (0.6199): no detecta al 38 % de las personas que ganan más de 50K, y ese error no se reparte igual entre los grupos.
- La regresión logística y el árbol de decisión rinden prácticamente igual; preferí la regresión logística porque se puede explicar.
- **Éticamente, el modelo no está listo para decisiones reales.** Reproduce las brechas de sexo y raza, y quitar las variables sensibles no las elimina.

Recomendaciones para Mejorar

La Tabla 9 resume las mejoras que propongo, agrupadas por tema.

Tabla 9

Recomendaciones de mejora del modelo y del proyecto

Ámbito	Recomendación
Desempeño	Ajustar el umbral (0.35 sube el F1 a 0.695); probar class_weight='balanced'; crear interacciones (edad × horas, educación × ocupación) o probar modelos no lineales (Random Forest, Gradient Boosting) comparándolos contra este modelo como referencia.
Datos	Usar datos recientes y locales (p. ej., la GEIH del DANE para Colombia); agrupar países por región; conseguir más ejemplos de los grupos subrepresentados.
Equidad	Aplicar mitigación con Fairlearn: reponderación en el preprocesamiento, ExponentiatedGradient con restricción de igualdad de oportunidad en el entrenamiento, o umbrales por grupo en el postprocesamiento. Reportar siempre las métricas por grupo junto a las globales.
Transparencia	Publicar una model card; agregar explicaciones locales (SHAP) por predicción; documentar el uso previsto y las prohibiciones de uso.
Validación	Validación cruzada repetida o anidada; intervalos de confianza por bootstrap; calibración de probabilidades (curva de confiabilidad).
Ingeniería	Integración continua (GitHub Actions) que ejecute pipeline + pytest en cada PR hacia develop; monitoreo de deriva si algún día se despliega.

Nota. La integración continua ya quedó implementada en el repositorio.

Referencias

Barocas, S., Hardt, M., & Narayanan, A. (2023). *Fairness and machine learning: Limitations and opportunities*. MIT Press. https://fairmlbook.org

Becker, B., & Kohavi, R. (1996). *Adult* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5XW20

Brown, S. (s.f.). *The C4 model for visualising software architecture*. Recuperado el 6 de noviembre de 2026, de https://c4model.com

Congreso de la República de Colombia. (2012, 17 de octubre). *Ley Estatutaria 1581 de 2012: Por la cual se dictan disposiciones generales para la protección de datos personales*.

Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. *Advances in Neural Information Processing Systems, 29*.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). Association for Computing Machinery. https://doi.org/10.1145/3287560.3287596

Nieto Rodríguez, S. (2026). *proyectoFinal_predictorIngresos* [Repositorio de código fuente]. GitHub. https://github.com/santnier92/proyectoFinal_predictorIngresos/tree/develop

Nygard, M. (2011, 15 de noviembre). *Documenting architecture decisions*. Cognitect. https://cognitect.com/blog/2011/11/15/documenting-architecture-decisions

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.