Actividad 6 · Mini-proyecto

Predictor de Ingresos: evaluación y análisis ético de un modelo de Regresión Logística

Teoría de la Computación II · Ingeniería de Software
Universidad de La Salle

Autor: Santiago Nieto Rodríguez (snieto21@unisalle.edu.co)
Docente: Rodrigo Aranda Fernández
Repositorio: github.com/santnier92/proyectoFinal_predictorIngresos
Rama individual: dev_snieto21 → **integración:** develop
Fecha: noviembre de 2026

Indicador clave (conjunto de prueba)	Valor
Accuracy / baseline	0.8562 / 0.7606
F1-score clase >50K	0.6736
ROC-AUC	0.9095
Criterios de aceptación cumplidos	5 de 5
Brecha de recall (TPR) hombres vs mujeres	0.170

1. Introducción y objetivo

Este mini-proyecto aplica un modelo básico de Machine Learning sobre un dataset público conocido, evalúa su desempeño con métricas cuantitativas y analiza desde una perspectiva ética sus sesgos, su impacto y sus límites. La tarea es una **clasificación binaria**: estimar si el ingreso anual de una persona supera **50.000 USD** (*>50K*, clase positiva = 1) a partir de sus atributos demográficos y laborales registrados en el censo de EE. UU. de 1994.

El sistema se construyó como un pipeline reproducible (`python -m src.pipeline`) que recorre las siete etapas del workflow de ML vistas en clase: definir la tarea, recolectar los datos, representar la entrada, elegir el modelo, entrenar, evaluar y usar el modelo con datos nuevos. La arquitectura, los ADR, los riesgos y el glosario están en el README del repositorio; este documento desarrolla el análisis de la actividad.

2. Selección del modelo

Se eligió la **Regresión Logística**. Este modelo estima la probabilidad de la clase positiva aplicando la función sigmoide a una combinación lineal de las variables: $P(y=1|x) = 1 / (1 + e^{-(\beta_0 + \beta \cdot x)})$. Las razones de la elección fueron:

- **Es adecuado para el problema:** la variable objetivo es binaria y los datos son tabulares.
- **Es interpretable:** cada coeficiente indica cuánto aumenta o disminuye el log-odds de ganar >50K. Esto es indispensable para el análisis ético, porque permite ver *qué* variables empujan la decisión.
- **Entrega probabilidades:** así se puede mover el umbral de decisión según el costo de cada tipo de error.
- **Su desempeño es equivalente al de un Árbol de Decisión:** el árbol obtuvo F1 = 0.6822 frente a 0.6736. La diferencia (0.009) es menor que la desviación estándar de la validación cruzada (0.012), así que no es significativa (ver ADR-002).
- Se descartó **KNN** porque, con 84 variables dispersas tras el one-hot, las distancias pierden sentido, predecir es costoso y el modelo no da una explicación global.

Hiperparámetro elegido por validación cruzada de 5 folds: **C = 1.0** (inverso de la regularización L2).

3. Descripción del dataset

Se usó el dataset **Adult / Census Income** (Becker & Kohavi. 1996). del UCI Machine Learning Repository. con licencia CC BY 4.0. Tiene **48.842 registros y 15 columnas**. La clase positiva (>50K) representa el **23.9 %**. así que los datos están **desbalanceados**. Hay 52 duplicados y valores faltantes (codificados como '?') en workclass (2.799). occupation (2.809) y native_country (857).

3.1 Variables

Variable	Tipo	Descripción	Uso en el modelo
age	Numérica	Edad en años	Feature
workclass	Categórica	Tipo de empleador	Feature
fnlwgt	Numérica	Peso muestral del censo	Descartada (no describe a la persona)
education	Categórica	Nivel educativo en texto	Descartada (redundante)
education_num	Numérica	Nivel educativo 1–16	Feature
marital_status	Categórica	Estado civil	Feature (proxy de sexo)
occupation	Categórica	Ocupación	Feature
relationship	Categórica	Rol en el hogar	Feature (proxy de sexo)
race	Categórica	Raza	Feature sensible / auditada
sex	Categórica	Sexo	Feature sensible / auditada
capital_gain / capital_loss	Numéricas	Ganancias y pérdidas de capital	Features
hours_per_week	Numérica	Horas trabajadas por semana	Feature
native_country	Categórica	País de origen	Feature sensible / auditada
income	Binaria	>50K (1) o <=50K (0)	Variable objetivo

3.2 Muestra de registros

age	workclass	education_num	occupation	sex	race	hours	income
39	State-gov	13	Adm-clerical	Male	White	40	<=50K
50	Self-emp-not-inc	13	Exec-managerial	Male	White	13	<=50K
38	Private	9	Handlers-cleaners	Male	White	40	<=50K
31	Private	14	Prof-specialty	Female	White	50	>50K
42	Private	13	Exec-managerial	Male	White	40	>50K

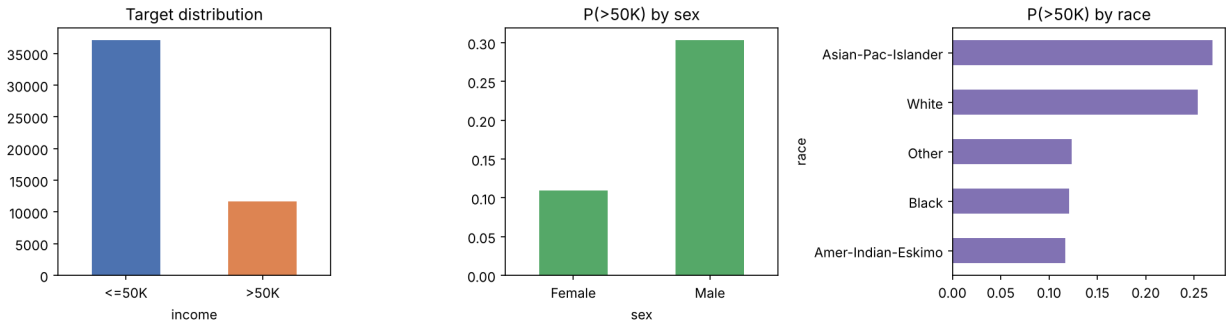


Figura 1. Distribución de la variable objetivo y proporción de >50K por sexo y por raza (datos originales).

Objetivo del modelo: aprender la relación entre las 12 variables de entrada y la variable *income*, para estimar la probabilidad de que una persona nueva gane más de 50K USD al año.

4. Metodología (workflow de ML)

Etapa	Qué se hizo
1. Definir la tarea	Clasificación binaria >50K vs <=50K; métrica principal: F1 de la clase positiva.
2. Recolectar datos	Carga del CSV de UCI con verificación SHA-256 y perfil del dataset.
3. Representar la entrada	Deduplicación antes de partir los datos (48.790 filas); partición estratificada 80/20 (train 39.032 / test 9.758); imputación (mediana / 'Unknown'). escalado estándar y one-hot (84 variables) dentro de un Pipeline.
4. Elegir el modelo	Baseline (clase mayoritaria), Regresión Logística, Árbol de Decisión y Regresión Logística sin atributos sensibles.
5. Entrenar	GridSearchCV con 5 folds estratificados, optimizando F1, solo sobre train.
6. Evaluar	Métricas en test, matriz de confusión, curva ROC, análisis de umbral, coeficientes, auditoría de equidad y criterios de aceptación.
7. Usar con datos nuevos	CLI src.predict: recibe un CSV y devuelve la probabilidad y la clase.

5. Métricas de evaluación

Todas las métricas se calcularon sobre el **conjunto de prueba** (9.758 registros), que no se usó ni en el entrenamiento ni en la selección de hiperparámetros.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Baseline (clase mayoritaria)	0.7606	0.0000	0.0000	0.0000	0.5000
Regresión Logística	0.8562	0.7376	0.6199	0.6736	0.9095
Árbol de Decisión	0.8660	0.7888	0.6010	0.6822	0.9113
Reg. Logística sin atributos sensibles	0.8554	0.7385	0.6130	0.6699	0.9090

5.1 Interpretación de cada métrica (Regresión Logística)

Métrica	Valor	Qué significa en este problema
Accuracy	0.8562	Acierta en el 85.6 % de las personas. **Ojo:** el baseline, que siempre responde <=50K, ya obtiene 76.1 % sin aprender nada. La ganancia real es de +9.6 puntos. Con clases desbalanceadas, la accuracy sola engaña.
Precision	0.7376	De cada 100 personas que el modelo clasifica como >50K, unas 74 realmente lo son. Mide qué tan confiable es una predicción positiva.
Recall	0.6199	Detecta el 62.0 % de quienes realmente ganan >50K; se le escapa el 38.0 %. Mide la cobertura de la clase positiva.
F1-score	0.6736	Media armónica entre precision y recall. Es la métrica principal porque castiga tanto los falsos positivos como los falsos negativos. El baseline obtiene 0.
ROC-AUC	0.9095	Si se toman al azar una persona con >50K y otra con <=50K, el modelo le asigna mayor probabilidad a la primera en el 91.0 % de los casos. No depende del umbral.
CV F1 (5 folds)	0.6565 ± 0.0118	Desempeño estable entre particiones distintas del entrenamiento: el resultado no depende de la suerte de la partición.

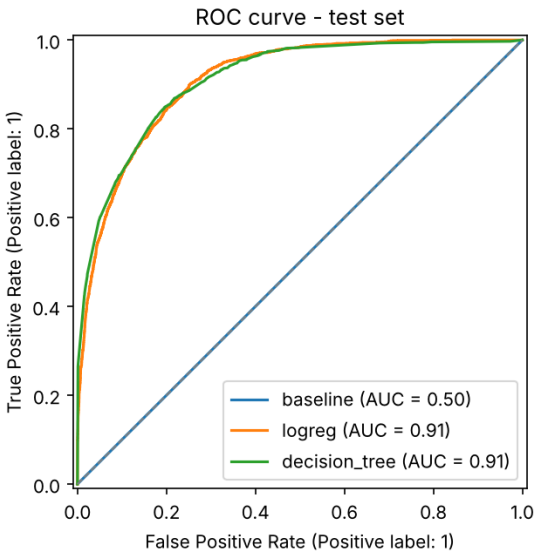


Figura 2. Curvas ROC en el conjunto de prueba. El baseline coincide con la diagonal (AUC 0.5).

Umbral de decisión. Con el umbral por defecto (0.5) el modelo prioriza la precisión. Si se baja a **0.35**, el F1 sube a **0.695**, porque el modelo gana recall a cambio de algo de precisión. La elección del umbral es una decisión de negocio y de ética: depende de qué error resulta más costoso en el contexto de uso.

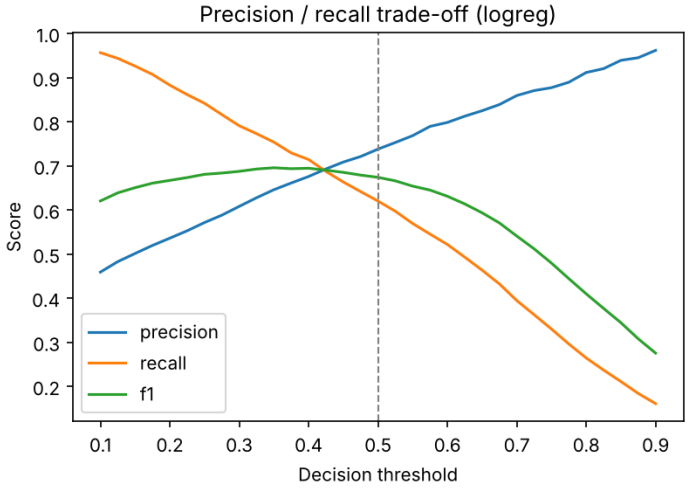


Figura 3. Precision, recall y F1 según el umbral de decisión.

6. Matriz de confusión

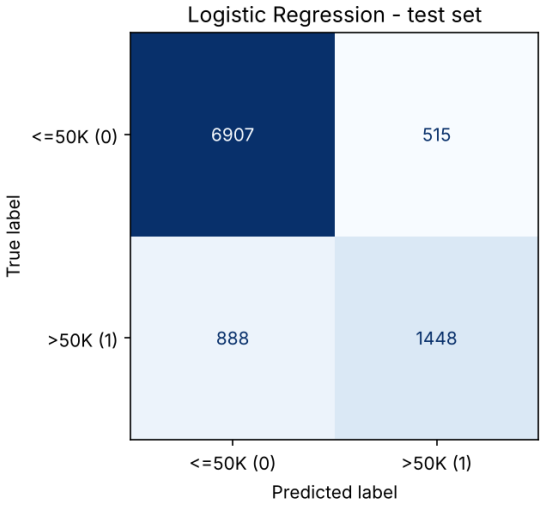


Figura 4. Matriz de confusión de la Regresión Logística (test, umbral 0.5).

Celda	Valor	Significado en este problema
Verdaderos positivos (VP)	1.448	Personas que ganan >50K y el modelo las identificó correctamente.
Falsos positivos (FP)	515	Personas que ganan <=50K, pero el modelo dijo >50K. En un uso real (p. ej., crédito) podría concederse un producto que la persona no puede pagar: es el error de *sobreestimar*.
Verdaderos negativos (VN)	6.907	Personas que ganan <=50K y el modelo lo clasificó correctamente. Es la celda más grande porque es la clase mayoritaria.
Falsos negativos (FN)	888	Personas que ganan >50K, pero el modelo dijo <=50K. Se les *subestima* y podrían perder oportunidades. Son la causa del recall de 0.62 y, como se verá en la sección 7, afectan más a mujeres y personas negras.

El modelo comete más falsos negativos (888) que falsos positivos (515): es **conservador** al asignar la clase >50K. Esto es esperable con datos desbalanceados y umbral 0.5. En comparación. el baseline tiene 0 VP y 2.336 FN: no detecta a ninguna persona de la clase positiva.

7. Análisis ético

7.1 Sesgos del dataset

- **Sesgo histórico:** el censo de 1994 refleja desigualdades estructurales de su época. El 30.4 % de los hombres gana >50K frente al 10.9 % de las mujeres, y las personas blancas y asiáticas superan en más del doble a las personas negras e indígenas. Un modelo entrenado con estos datos aprende esas brechas como si fueran patrones "naturales".
- **Sesgo de representación:** el 85.5 % de los registros corresponde a personas blancas y el 66.8 % a hombres. Grupos como Amer-Indian-Eskimo (~470 registros) u Other (~400) tienen tan pocos datos que sus métricas no son confiables.
- **Sesgo de medición:** las categorías de raza y sexo son binarias o cerradas, el umbral de 50K está fijo en dólares de 1994 y no se ajusta por costo de vida ni por región.
- **Sesgo temporal y geográfico:** los datos no representan la economía actual ni a Colombia; aplicar el modelo fuera de ese contexto sería una extrapolación inválida.

7.2 Sesgos del modelo

Los coeficientes muestran que el modelo usa directamente el sexo: **sex_Female** tiene un coeficiente de **-0.967** (log-odds), es decir, a igualdad de las demás variables, ser mujer reduce la probabilidad estimada de ganar >50K. También pesan mucho **marital_status = Married-civ-spouse** (+1.41) y **relationship = Own-child** (-0.98), variables que funcionan como **proxy** del sexo y de la etapa de vida. Por último, algunos países poco frecuentes (por ejemplo, Columbia: -1.05) reciben coeficientes extremos con muy pocos ejemplos, lo que muestra inestabilidad y riesgo de discriminación por origen.

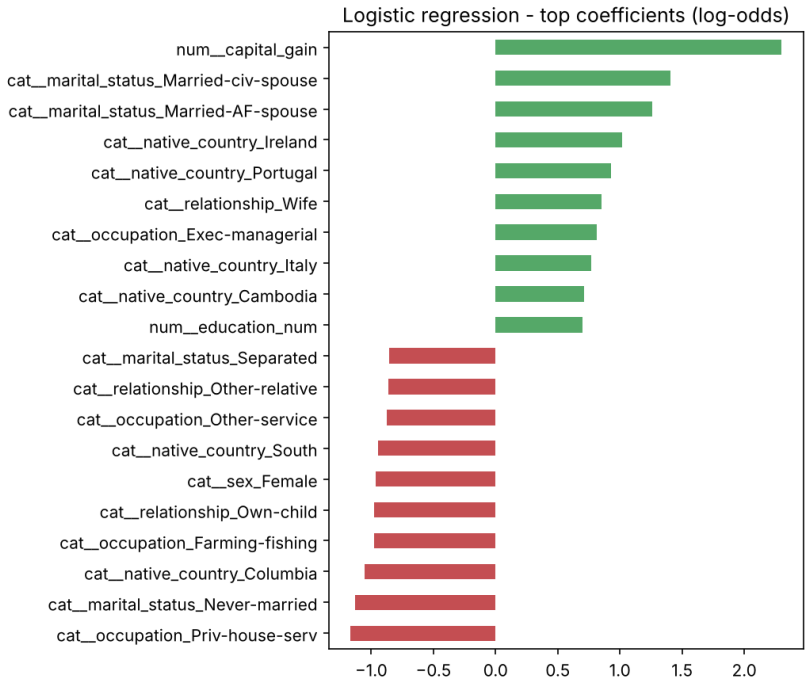


Figura 5. Los 20 coeficientes de mayor magnitud de la Regresión Logística.

7.3 Equidad: métricas por grupo

Para la auditoría se usaron dos criterios: **paridad demográfica** (¿se predice >50K con la misma frecuencia en cada grupo?) e **igualdad de oportunidad** (¿el modelo detecta por igual, con el mismo recall o TPR, a las personas de cada grupo que sí ganan >50K?).

Grupo	n (test)	Tasa real >50K	Tasa predicha >50K	TPR (recall)	FPR	Accuracy
Male	6432	0.304	0.269	0.648	0.104	0.821
Female	3326	0.115	0.070	0.478	0.017	0.925
White	8353	0.255	0.216	0.628	0.074	0.850
Black	916	0.123	0.079	0.460	0.025	0.912
Asian-Pac-Islander	311	0.228	0.244	0.676	0.117	0.836

- **Sexo:** el modelo detecta al 64.8 % de los hombres con >50K, pero solo al 47.8 % de las mujeres con >50K (diferencia de igualdad de oportunidad = 0.170). Una mujer que sí gana bien tiene más probabilidad de ser subestimada.
- **Raza:** el TPR de las personas negras (46.0 %) es mucho menor que el de las personas blancas (62.8 %); la diferencia máxima entre grupos es 0.216.
- **Impacto dispar:** la razón entre tasas de selección por sexo es 0.26, muy por debajo de la regla de los cuatro quintos (0.80) que se usa como referencia en contextos laborales de EE. UU.
- **Accuracy engañosa:** la accuracy es *mayor* en mujeres (92.5 %) que en hombres, porque en ellas la mayoría pertenece a la clase <=50K. Por eso no basta con mirar la accuracy por grupo: hay que revisar el recall.
- **"Equidad por ceguera" no funciona:** al quitar sex, race y native_country, la paridad por sexo apenas pasa de 0.199 a 0.192 y la de oportunidad de 0.170 a 0.146, porque relationship (Husband/Wife) y marital_status siguen codificando el sexo.

7.4 Privacidad y uso responsable de los datos

- El dataset es público, está anonimizado (no tiene nombres ni identificadores) y su licencia (CC BY 4.0) permite usarlo con atribución, que se da en las referencias.
- Aun así, contiene **datos sensibles** (raza, sexo, origen, estado civil). En Colombia, la Ley 1581 de 2012 exige autorización previa, finalidad explícita y medidas reforzadas para este tipo de datos; un sistema real no podría usarlos sin cumplir esos requisitos.
- Riesgo de **reidentificación**: combinando edad, ocupación, país y horas trabajadas se podría aislar a una persona en una población pequeña. Por eso el modelo no se expone como servicio ni se cruza con otras fuentes.
- **Minimización:** se descartó fnlwgt y se recomienda no recolectar atributos que el caso de uso no necesite.

7.5 Impacto social

Si un modelo así se usara para decidir créditos, cupos, contrataciones o subsidios, sus falsos negativos se concentrarían en mujeres y personas negras: se les negarían oportunidades a quienes sí cumplen el criterio, reforzando la desigualdad que originó los datos (**bucle de retroalimentación**). Al revés, los falsos positivos podrían llevar a sobreendeudamiento. El impacto no es neutro aunque el algoritmo lo sea matemáticamente.

7.6 Justicia y transparencia en la toma de decisiones

- **Transparencia:** la Regresión Logística permite explicar cada predicción (contribución de cada variable), y el repositorio publica datos, código, métricas por grupo y decisiones (ADR) para que terceros puedan auditarlo.
- **Justicia:** no existe una única definición de equidad. La paridad demográfica y la igualdad de oportunidad no pueden cumplirse a la vez cuando las tasas base difieren (30 % vs 11 %), así que elegir una es una decisión ética que deben tomar los interesados, no solo el equipo técnico.
- **Supervisión humana:** el modelo debe ser una herramienta de apoyo, no la decisión final. Las personas afectadas deberían poder conocer la razón de la decisión y apelarla.
- **Rendición de cuentas:** se recomienda acompañar el modelo de una *model card* que declare el uso previsto, los límites y las métricas por grupo.

8. Conclusiones técnicas

- El modelo **funciona bien desde el punto de vista técnico**: F1 = 0.6736, ROC-AUC = 0.9095 y accuracy = 0.8562. Supera ampliamente al baseline (F1 0 y AUC 0.5) y cumple los **5 de 5 criterios de aceptación** definidos.
- **No hay sobreajuste:** el F1 de train (0.6588) y el de test (0.6736) son prácticamente iguales, y la variación entre folds es baja (± 0.0118).
- **Los resultados son válidos:** no hay registros compartidos entre train y test, y el F1 sobre perfiles nunca vistos (0.691) es incluso mayor que sobre perfiles repetidos (0.602).
- Su **debilidad principal es el recall** (0.6199): no detecta al 38 % de las personas con >50K, y ese error se distribuye de forma desigual entre grupos.
- La Regresión Logística y el Árbol de Decisión rinden de forma equivalente; la logística se prefiere por su interpretabilidad.
- **Desde la ética, el modelo no es apto para decisiones reales:** reproduce brechas de sexo y raza, y quitar los atributos sensibles no las elimina.

9. Recomendaciones para mejorar

Ámbito	Recomendación
Desempeño	Ajustar el umbral (0.35 sube el F1 a 0.695); probar class_weight='balanced'; crear interacciones (edad × horas, educación × ocupación) o probar modelos no lineales (Random Forest, Gradient Boosting) comparándolos contra este modelo como referencia.
Datos	Usar datos recientes y locales (p. ej., la GEIH del DANE para Colombia); agrupar países por región; conseguir más ejemplos de los grupos subrepresentados.
Equidad	Aplicar mitigación con Fairlearn: reponderación en el preprocesamiento, ExponentiatedGradient con restricción de igualdad de oportunidad en el entrenamiento, o umbrales por grupo en el postprocesamiento. Reportar siempre las métricas por grupo junto a las globales.
Transparencia	Publicar una model card; agregar explicaciones locales (SHAP) por predicción; documentar el uso previsto y las prohibiciones de uso.
Validación	Validación cruzada repetida o anidada; intervalos de confianza por bootstrap; calibración de probabilidades (curva de confiabilidad).
Ingeniería	Integración continua (GitHub Actions) que ejecute pipeline + pytest en cada PR hacia develop; monitoreo de deriva si algún día se despliega.

10. Referencias

- Becker, B., & Kohavi, R. (1996). *Adult* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5XW20
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825–2830.
- Barocas, S., Hardt, M., & Narayanan, A. (2023). *Fairness and Machine Learning*. MIT Press. https://fairmlbook.org
- Hardt, M., Price, E., & Srebro, N. (2016). Equality of Opportunity in Supervised Learning. *NeurIPS*.
- Mitchell, M. et al. (2019). Model Cards for Model Reporting. *FAT* '19*.
- Brown, S. *The C4 model for visualising software architecture*. https://c4model.com
- Nygard, M. (2011). Documenting Architecture Decisions. Cognitect.
- Congreso de Colombia (2012). Ley Estatutaria 1581 de 2012 — Protección de datos personales.